Aprendizado de Máquina & Deep Learning

Notas de Aula

Pedro Watuhã dos Santos Guerra

2026

Um texto de pós-graduação autocontido cobrindo teoria do aprendizado estatístico, regularização, conjuntos de árvores, redes neurais, modelos variacionais e generativos, inferência causal e double machine learning.

Agradecimentos

O autor agradece o apoio da **CAPES** (Coordenação de Aperfeiçoamento de Pessoal de Nível Superior), Brasil, pelo financiamento desta pesquisa e pelo suporte ao desenvolvimento deste material didático sob o Programa de Bolsas de Pós-Graduação da CAPES.

Estas notas cresceram a partir de aulas ministradas em 2026 e se inspiram em décadas de sabedoria acumulada em teoria do aprendizado estatístico e aprendizado de máquina.

Prefácio

Estas notas cobrem oito aulas sobre aprendizado de máquina e deep learning sob uma perspectiva estatística unificada. A filosofia organizadora é consistente ao longo de todo o texto: todo algoritmo tem uma razão matemática para funcionar, e todo teorema tem uma consequência algorítmica.

Escopo e arco. As oito aulas formam uma progressão natural. Começamos com os fundamentos da *teoria de generalização* (Aula 1). As Aulas 2–4 desenvolvem as três famílias canônicas de métodos de predição — modelos lineares regularizados, conjuntos de árvores e redes neurais — cada um com suas garantias teóricas e taxas de convergência conhecidas. As Aulas 5–6 voltam-se à *modelagem generativa*. As Aulas 7–8 fecham o curso com *inferência causal*, culminando no Double Machine Learning.

Pré-requisitos. Probabilidade ao nível de pós-graduação; álgebra linear; análise real básica; Python (NumPy, scikit-learn, PyTorch).

Notação. $\mathbb{E}$: esperança; $\mathbb{E}_n f = \frac{1}{n}\sum_i f(x_i)$: média empírica; $O_{\mathbb{P}}(\cdot)$, $o_{\mathbb{P}}(\cdot)$: grande-O e pequeno-o estocásticos.

Sumário

Agradecimentos **i**

Prefácio **ii**

1 Teoria do Aprendizado Estatístico **1**
1.1 O Problema do Aprendizado Supervisionado . . . 1
1.2 Concentração: Desigualdade de Hoeffding . . . 2
1.3 Complexidade de Rademacher . . . 2
1.4 Dimensão VC e Lema de Sauer . . . 3
1.5 Decomposição Viés–Variância . . . 4

2 Regularização **5**
2.1 O Modelo Linear e Seus Limites . . . 5
2.2 Regressão Ridge . . . 5
2.3 O LASSO . . . 6
2.3.1 Descida por Coordenadas . . . 7
2.3.2 Teoria Estatística: Esparsidade e Taxas . . . 7

3 Árvores de Decisão e Florestas Aleatórias **9**
3.1 Árvores de Decisão . . . 9
3.1.1 O Algoritmo CART . . . 9
3.1.2 Desequilíbrio Viés–Variância em Árvores . . . 10
3.2 Métodos de Ensemble . . . 10
3.3 Florestas Aleatórias . . . 11
3.3.1 Erro Out-of-Bag . . . 11
3.4 Overfitting Benigno e Dupla Descida . . . 11

4 Redes Neurais e Teoria da Aproximação **13**
4.1 O Perceptron . . . 13
4.2 Perceptrons Multicamadas . . . 14
4.3 Retropropagação . . . 14
4.4 Teoria da Aproximação . . . 15

5 Inferência Variacional, VAEs e Dinâmica de Langevin **16**
5.1 De Predição à Modelagem Generativa . . . 16
5.2 Entropia e Divergência KL . . . 16
5.3 O Limitante Inferior da Evidência (ELBO) . . . 17
5.4 Inferência Variacional . . . 18

5.4.1 Campo Médio e CAVI 18
5.5 Autoencoder Variacional (VAE) 18
5.5.1 O Truque da Reparametrização 18
5.6 Dinâmica de Langevin 19

6 Modelos de Difusão e Flow Matching **20**
6.1 DDPM: Modelos Probabilísticos de Difusão com Denoisificação 20
6.1.1 O Processo Direto 20
6.1.2 Processo Reverso e Objetivo de Treino 21
6.2 Score Matching 21
6.3 Flow Matching 22

7 Inferência Causal **24**
7.1 Por Que Causalidade Não se Reduz a Correlação 24
7.2 A Escada da Causalidade de Pearl 24
7.3 Framework de Resultados Potenciais 25
7.4 Modelos Causais Estruturais e DAGs 25
7.5 Variáveis Instrumentais 26
7.6 Descoberta Causal: Algoritmo PC 27

8 Double Machine Learning **28**
8.1 O Problema: Controles de Alta Dimensão com Inferência Válida 28
8.2 O Modelo Parcialmente Linear 28
8.3 Decomposição de Robinson e Partialling-Out 29
8.4 A Solução DML 29
8.4.1 De $a + b$ a $a^* + b^* + c^*$ 29
8.4.2 Ingrediente 1: Ortogonalidade de Neyman 29
8.4.3 Ingrediente 2: Validação Cruzada (Cross-Fitting) 30
8.5 As Condições de Taxa São Alcançáveis? 30
8.6 Modelo Interativo e Estimação Duplamente Robusta 31
8.7 Variáveis Instrumentais no Framework DML 31

Referências **32**

Lista de Figuras

1.1 Largura do intervalo de confiança de Hoeffding (95%) em função do tamanho amostral n. A largura decresce como $O(n^{-1/2})$. 2

1.2 Troca viés–variância em regressão polinomial ($n = 200$, validação cruzada 5-fold). O erro de teste cresce drasticamente para graus elevados (sobreajuste). 4

2.1 (a) O operador $S_\lambda(z)$ anula coeficientes menores que λ em módulo. (b) Os coeficientes do LASSO atingem zero em λ finito (esparsidade); os da ridge se aproximam assintoticamente. 7

3.1 Viés ao quadrado, variância e EQM de teste vs. profundidade da árvore em um problema de regressão 1D. A variância cresce monotonicamente com a profundidade; o viés decresce. 10

3.2 Curva de dupla descida: EQM de teste vs. dimensão p para regressão linear com $n = 50$. O pico em $p = n$ é o limiar de interpolação; para $p \gg n$, o interpolante de norma mínima tem viés e variância decrescentes. 12

4.1 Cinco funções de ativação comuns. ReLU é o padrão do deep learning moderno. GELU (usado em Transformers) aproxima ReLU suavemente. . . 14

5.1 KL direta vs. reversa em um alvo bimodal $p(z|x)$. A KL direta produz aproximação cobridora e ampla; a KL reversa produz aproximação buscadora de modo e estreita. 17

6.1 Processo de difusão direta: a distribuição $q(x_t|x_0)$ para $x_0 = 2$ torna-se progressivamente mais larga e centrada em zero. Em $t = T$, o sinal é destruído e $q(x_T|x_0) \approx \mathcal{N}(0, 1)$. 21

6.2 Função score de $p(x) = 0.5\mathcal{N}(-2, 1) + 0.5\mathcal{N}(2, 1)$. O score (vermelho) aponta para os dois modos; a dinâmica de Langevin seguindo este campo converge para amostras de p. 22

6.3 Flow Matching Gaussiano: 20 caminhos lineares de $\mathcal{N}(\mathbf{0}, \boldsymbol{I})$ a uma mistura de 3 Gaussianas. Cada caminho tem velocidade constante $x_1 - x_0$; nenhuma simulação de EDO é necessária durante o treino. 23

7.1 DAG de variável instrumental. Z (instrumento) não tem caminho direto para Y e é independente do confundidor não-observado U (tracejado). . . . 26

8.1 Distribuição amostral de $\sqrt{n}(\hat{\theta} - \theta_0)$ em 500 simulações. Esquerda: MQO plug-in — viesado, não-normal. Centro: LASSO plug-in — viesado. Direita: DML com cross-fitting — centrado em zero, bem-aproximado por $N(0, \Sigma)$. . 30

Aula 1

Teoria do Aprendizado Estatístico

Nota Histórica: O Nascimento da Teoria do Aprendizado Estatístico

O estudo formal de quando e por que o aprendizado a partir de dados funciona data dos anos 1960–1980. Vapnik e Chervonenkis (1971) provaram os primeiros resultados de convergência uniforme e introduziram a dimensão VC. Valiant (1984) formalizou o framework PAC (*Probably Approximately Correct*). A complexidade de Rademacher emergiu mais tarde, com Bartlett e Mendelson (2002).

1.1. O Problema do Aprendizado Supervisionado

Observamos n exemplos rotulados $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ amostrados i.i.d. de P_{XY}. Queremos $f : \mathcal{X} \to \mathcal{Y}$ que generalize bem a dados futuros.

Definição: Risco Populacional e Empírico

O **risco populacional**: $R(f) = \mathbb{E}_{(X,Y)\sim P}[\ell(f(X), Y)]$. O **risco empírico**: $R_n(f) = \frac{1}{n}\sum_{i=1}^n \ell(f(x_i), y_i)$.

Definição: Minimização do Risco Empírico (ERM)

Dada $\mathcal{H}$: $\widehat{f}_n = \arg\min_{f\in\mathcal{H}} R_n(f)$.

1.1.1. O Preditor Ótimo de Bayes

Classificador Ótimo de Bayes (perda 0-1)

Seja $\eta(x) = P(Y = 1|X = x)$. O minimizador do risco populacional é $f^*(x) = \mathbb{1}[\eta(x) \geq 1/2]$.

Demonstração

Pela lei da esperança total: $R(h) = \mathbb{E}_X[P(Y \neq h(X)|X)]$. Se $h(x) = 1$: $P(Y \neq 1|X = x) = 1 - \eta(x)$. Se $h(x) = 0$: $P(Y \neq 0|X = x) = \eta(x)$. Para minimizar pontualmente: saída 1 quando $\eta(x) \geq 1/2$. □

Regressor Ótimo de Bayes (perda quadrática)

Sob perda quadrática: $f^*(x) = \mathbb{E}[Y|X = x]$, com risco irredutível $R^* = \mathbb{E}[\mathrm{Var}(Y|X)]$.

Demonstração

Escreva $Y = f^*(X) + \eta$ com $\mathbb{E}[\eta|X] = 0$. Para qualquer h: $R(h) = \mathbb{E}[(h(X) - f^*(X))^2] + \mathbb{E}[\mathrm{Var}(Y|X)]$. Mínimo quando $h = f^*$. □

1.1.2. Realizabilidade vs. Agnosticismo

Caso realizável: $f^* \in \mathcal{H}$ (erro de aproximação zero). **Caso agnóstico:** $f^* \notin \mathcal{H}$ (erro de aproximação > 0). Problemas reais são agnósticos.

A diferença $R(\widehat{f}_n) - R_n(\widehat{f}_n)$ é a *lacuna de generalização*. Decompõe-se em erro de estimação e erro de aproximação:

$$R(\widehat{f}_n) - R(f^*) = \underbrace{R(\widehat{f}_n) - \inf_{f \in \mathcal{H}} R(f)}_{\text{erro de estimação}} + \underbrace{\inf_{f \in \mathcal{H}} R(f) - R(f^*)}_{\text{erro de aproximação}}.$$

1.2. Concentração: Desigualdade de Hoeffding

Desigualdade de Hoeffding

Sejam $Z_1, \ldots, Z_n$ i.i.d., $Z_i \in [a_i, b_i]$ q.c., $\mathbb{E}[\bar{Z}] = \mu$. Para $t > 0$:

$$\mathbb{P}(\bar{Z} - \mu \geq t) \leq \exp\left(\frac{-2n^2t^2}{\sum_i (b_i - a_i)^2}\right).$$

Para perdas em $[0, 1]$: $\mathbb{P}(R_n(f) - R(f) \geq t) \leq e^{-2nt^2}$.

Demonstração

O ingrediente central é o **Lema de Hoeffding**: se $Z \in [a, b]$ e $\mathbb{E}[Z] = 0$, então $\mathbb{E}[e^{sZ}] \leq \exp(s^2(b - a)^2/8)$. Prova-se por convexidade de e^{sz}: $e^{sz} \leq \frac{b-z}{b-a}e^{sa} + \frac{z-a}{b-a}e^{sb}$. Tomando esperanças e otimizando em $s > 0$ via Markov aplicado a $e^{s(\bar{Z}-\mu)}$ completa a demonstração. □

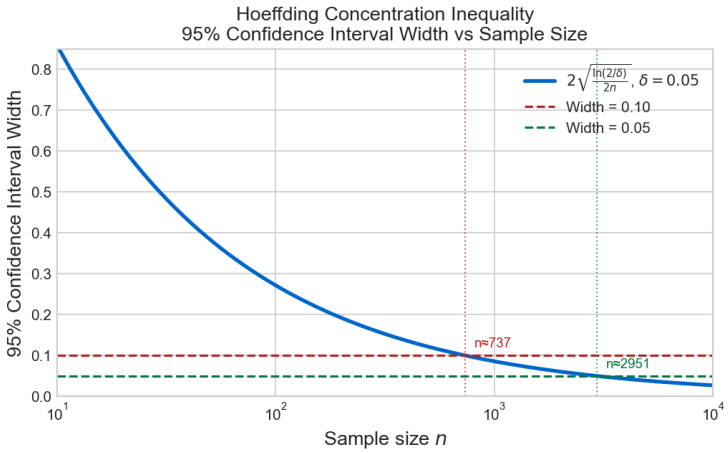

Figura 1.1: Largura do intervalo de confiança de Hoeffding (95%) em função do tamanho amostral n. A largura decresce como $O(n^{-1/2})$.

1.2.1. Classes de Hipóteses Finitas

Complexidade Amostral para Classes Finitas

Se $|\mathcal{H}| < \infty$ e $\ell \in [0, 1]$, então com $n \geq \log(|\mathcal{H}|/\delta)/(2\varepsilon^2)$: $\mathbb{P}[\exists h \in \mathcal{H} : R(h) - R_n(h) \geq \varepsilon] \leq \delta$.

Demonstração

Pelo **argumento da união**: $\mathbb{P}[\exists h : R(h) - R_n(h) \geq \varepsilon] \leq \sum_h e^{-2n\varepsilon^2} = |\mathcal{H}|e^{-2n\varepsilon^2} \leq \delta$. □

1.2.2. Desigualdade de McDiarmid

Desigualdade de McDiarmid (1989)

Sejam $Z_1, \ldots, Z_n$ independentes e $\Phi : \mathcal{Z}^n \to \mathbb{R}$ satisfazendo a **condição de diferenças limitadas**: $|\Phi(\ldots, z_i, \ldots) - \Phi(\ldots, z_i', \ldots)| \leq c_i$. Então: $\mathbb{P}(\Phi(Z) - \mathbb{E}[\Phi(Z)] \geq \varepsilon) \leq \exp(-2\varepsilon^2/\sum_i c_i^2)$.

Intuição. Enquanto Hoeffding controla médias, McDiarmid controla funções gerais cujo valor é pouco sensível à substituição de qualquer ponto. Para $\Phi(S) = \sup_{f \in \mathcal{H}}[R(f) - R_n(f)]$: $c_i = 2/n$, dando $\mathbb{P}(\Phi - \mathbb{E}[\Phi] \geq \varepsilon) \leq e^{-n\varepsilon^2/2}$.

1.3. Complexidade de Rademacher

Para $\mathcal{F}$ e $S = (x_1, \ldots, x_n)$:

$$\widehat{\mathfrak{R}}_n(\mathcal{F}) = \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_i \sigma_i f(x_i) \right],$$

onde $\sigma_i \overset{\text{i.i.d.}}{\sim} \text{Uniforme}\{-1, +1\}$.

Intuição. Os σ_i são rótulos de ruído puro. A complexidade mede quão bem $\mathcal{F}$ consegue correlacionar-se com ruído aleatório. Classes com baixa complexidade de Rademacher generalizam bem.

Limitante de Generalização via Rademacher (Bartlett & Mendelson, 2002)

Com probabilidade $\geq 1 - \delta$ sobre $S \sim P^n$:

$$\sup_{f \in \mathcal{H}} [R(f) - R_n(f)] \leq 2\mathfrak{R}_n(\mathcal{H}) + \sqrt{\frac{\log(1/\delta)}{2n}}.$$

Esboço da Demonstração

Passo 1 (Simetrização). Introduza uma "amostra fantasma" S' i.i.d. de P. Pela lei dos grandes números: $R(f) - R_n^S(f) = \mathbb{E}_{S'}[R_n^{S'}(f) - R_n^S(f)]$. Tomando supremo e esperança, e usando a desigualdade de Jensen:

$$\mathbb{E}_S \sup_f [R(f) - R_n^S(f)] \leq \mathbb{E}_{S,S'} \sup_f [R_n^{S'}(f) - R_n^S(f)].$$

Passo 2 (Rademarização). Como (x_i, x_i') é par simétrico, multiplicar por $\sigma_i \in \{-1, +1\}$ não muda a distribuição. Isso introduz a complexidade de Rademacher.
Passo 3 (McDiarmid). $\Phi(S) = \sup_f [R(f) - R_n^S(f)]$ muda no máximo $2/n$ ao substituir qualquer x_i. A desigualdade de McDiarmid fornece a correção $\sqrt{\log(1/\delta)/(2n)}$. $\square$

1.4. Dimensão VC e Lema de Sauer

Definição: Dimensão VC

$\mathcal{H}$ **fragmenta** C se para toda rotulagem de C, algum $h \in \mathcal{H}$ a classifica corretamente. $\text{VC}(\mathcal{H}) = \sup\{|C| : \mathcal{H} \text{ fragmenta } C\}$.

Lema de Sauer–Shelah

Com $d = \text{VC}(\mathcal{H})$:

$$\Pi_{\mathcal{H}}(n) \leq \sum_{i=0}^{d} \binom{n}{i} \leq \left(\frac{en}{d}\right)^d.$$

Demonstração

Por indução em $n + d$. Para n fixo, fixe x_n e decomponha $\mathcal{H}_S = \mathcal{H}^0 \cup \mathcal{H}^1$ de acordo com as classificações de x_n. Por indução: $|\mathcal{H}^0| \leq \Pi_{\mathcal{H}}(n-1)$ e $|\mathcal{H}^1 \setminus \mathcal{H}^0| \leq \Pi_{\mathcal{H}'}(n-1)$ com $\text{VC}(\mathcal{H}') \leq d - 1$. Portanto $\Pi_{\mathcal{H}}(n) \leq \Pi_{\mathcal{H}}(n-1) + \Pi_{\mathcal{H}'}(n-1) \leq \sum_{i=0}^{d} \binom{n}{i}$. $\square$

Teorema Fundamental do Aprendizado Estatístico

Para classificação binária com perda 0-1, os seguintes são equivalentes:

(i) $\mathcal{H}$ é PAC aprendível agnóstico.

(ii) $\mathcal{H}$ tem a propriedade de convergência uniforme.

(iii) $d = \mathrm{VC}(\mathcal{H}) < \infty$.

Complexidade amostral: $\Omega\left(\frac{d+\log(1/\delta)}{\varepsilon^2}\right) \leq m_{\mathcal{H}}(\varepsilon, \delta) \leq O\left(\frac{d\log(1/\varepsilon)+\log(1/\delta)}{\varepsilon^2}\right)$.

Consequência prática. O limitante VC não é dependente de dados: podemos minimizar $R_n(h) + \varepsilon_n(\mathcal{H}, \delta)$ sobre uma coleção $\mathcal{H}_1 \subset \mathcal{H}_2 \subset \cdots$, selecionando a melhor classe via ajuste de hiperparâmetros (**minimização do risco estrutural**).

1.5. Decomposição Viés–Variância

Decomposição Viés–Variância

Para perda quadrática e $\hat{f}_n$ qualquer:

$$\mathbb{E}[(Y - \hat{f}_n(x))^2] = \underbrace{(f^*(x) - \mathbb{E}[\hat{f}_n(x)])^2}_{\text{Viés}^2} + \underbrace{\mathrm{Var}(\hat{f}_n(x))}_{\text{Variância}} + \sigma^2.$$

Demonstração

Seja $\bar{f} = \mathbb{E}[\hat{f}_n]$. Escreva $Y = f^* + \eta$, $\mathbb{E}[\eta] = 0$, $\mathbb{E}[\eta^2] = \sigma^2$:

$$\begin{aligned}\mathbb{E}[(Y - \hat{f}_n)^2] &= \mathbb{E}[(f^* - \hat{f}_n)^2] + \sigma^2 \quad (\hat{f}_n \perp\!\!\!\perp \eta | x) \\ &= (f^* - \bar{f})^2 + \mathbb{E}[(\hat{f}_n - \bar{f})^2] + 2(f^* - \bar{f})\underbrace{\mathbb{E}[\hat{f}_n - \bar{f}]}_{=0} + \sigma^2.\end{aligned}$$

□

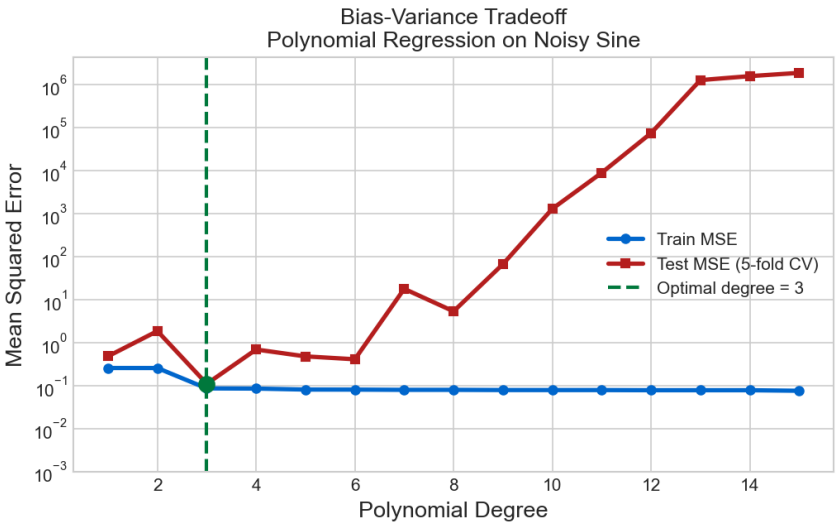

Figura 1.2: Troca viés–variância em regressão polinomial ($n = 200$, validação cruzada 5-fold). O erro de teste cresce drasticamente para graus elevados (sobreajuste).

Aula 2

Regularização

Nota Histórica: De MQO à Regressão Regularizada

Mínimos Quadrados Ordinários remonta a Gauss e Legendre (1805). A regressão ridge foi introduzida por Hoerl e Kennard (1970) como remédio para a multicolinearidade. O LASSO foi proposto por Tibshirani (1996), inspirado em trabalhos de busca de bases em processamento de sinais. Garantias teóricas para o LASSO sob esparsidade foram estabelecidas por Bickel, Ritov e Tsybakov (2009).

2.1. O Modelo Linear e Seus Limites

Para $Y = \boldsymbol{x}^\top \beta^* + \varepsilon$, o estimador MQO $\widehat{\beta} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}$ requer $p \leq n$ e posto completo. Quando $p > n$, está mal-definido. Quando há multicolinearidade quase-perfeita, a variância explode.

A solução: tolerar um pequeno viés para reduzir dramaticamente a variância e melhorar o erro quadrático médio.

2.1.1. Taxa Paramétrica

Taxa Paramétrica do MQO

Sob $Y = \boldsymbol{X}\beta^* + \varepsilon$: $\widehat{\beta} - \beta^* = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \varepsilon$, logo $\mathbb{E}[\left\|\widehat{\beta} - \beta^*\right\|^2] = \sigma^2 \operatorname{tr}((\boldsymbol{X}^\top \boldsymbol{X})^{-1}) = O(p/n)$.

2.1.2. Limitante Inferior Minimax

Taxa Minimax para Regressão Esparsa

Para $\beta^* \in \Sigma(s, p) = \{\beta : \|\beta\|_0 \leq s\}$: $\inf_{\hat{\beta}} \sup_{\beta^*} \mathbb{E}[\left\|\hat{\beta} - \beta^*\right\|^2] \asymp s \log(p/s)/n$.

Esboço do limitante inferior (Varshamov–Gilbert + Fano)

Construir um empacotamento finito $\{S_0, \ldots, S_M\}$ via Varshamov–Gilbert com $M \geq 2^{s\log(p/s)/8}$ e separação mínima c. A desigualdade de Fano aplicada com controle de KL para ruído Gaussiano fornece a taxa. □

Observação das notas de mão

A taxa minimax não-paramétrica para funções Lipschitz em $\mathbb{R}^d$ é $n^{-2/(d+2)}$. Florestas aleatórias podem bater essa taxa quando a função tem estrutura adicional (esparsidade, manifold de baixa dimensão), adaptando-se à dimensão efetiva em vez da dimensão ambiente.

2.2. Regressão Ridge

Definição: Regressão Ridge (Regularização de Tikhonov)

$$\widehat{\beta}_{\text{ridge}} = \arg\min_{\beta} \left\{ \|\boldsymbol{Y} - \boldsymbol{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\} = (\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})^{-1} \boldsymbol{X}^\top \boldsymbol{Y}.$$

Demonstração

O objetivo $\mathcal{L}(\beta) = \|\boldsymbol{Y} - \boldsymbol{X}\beta\|^2 + \lambda \|\beta\|^2$ é estritamente convexo. Igualando o gradiente a zero: $-2\boldsymbol{X}^\top(\boldsymbol{Y} - \boldsymbol{X}\beta) + 2\lambda\beta = 0 \implies (\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})\beta = \boldsymbol{X}^\top \boldsymbol{Y}$. Como $\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I} \succ 0$ para $\lambda > 0$, a solução existe e é única. □

Análise via SVD. Com $\boldsymbol{X} = \boldsymbol{U}\boldsymbol{D}\boldsymbol{V}^\top$: $\widehat{\beta}_{\text{ridge}} = \sum_j \frac{d_j^2}{d_j^2+\lambda} \cdot \frac{\boldsymbol{u}_j^\top \boldsymbol{Y}}{d_j} \boldsymbol{v}_j$. O fator $d_j^2/(d_j^2 + \lambda)$ contrai as direções de baixo valor singular — exatamente as direções de alta variância do MQO.

Viés e Variância da Ridge

$\text{Viés}(\widehat{\beta}_{\text{ridge}}) = -\lambda(\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})^{-1}\beta^*$, $\quad \text{Var}(\widehat{\beta}_{\text{ridge}}) = \sigma^2(\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})^{-1} \boldsymbol{X}^\top \boldsymbol{X} (\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})^{-1}$.

Interpretação Bayesiana. Ridge equivale à estimação MAP com prior Gaussiano $\beta \sim \mathcal{N}(0, \sigma^2 \boldsymbol{I}/\lambda)$: a estimativa ridge é a moda da posterior.

2.2.1. Desigualdade de Oráculo para Ridge

Desigualdade de Oráculo para Ridge

Se a perda é convexa e ρ-Lipschitz, $\|x_i\| \leq 1$:

$$\mathbb{E}[R(\widehat{\beta}_{\text{ridge}})] \leq R(\beta^*) + \lambda \|\beta^*\|^2 + \frac{\rho^2}{2\lambda\sqrt{n}}.$$

Otimizando λ: excesso de risco $= O(\rho \|\beta^*\| / n^{1/4})$ — **independente de p!**

2.2.2. Condições para Recuperação de Suporte

Hierarquia de Condições para o LASSO

(i) **RIP**: $(1-\delta)\|\beta\|^2 \leq \frac{1}{n}\|\boldsymbol{X}\beta\|^2 \leq (1+\delta)\|\beta\|^2$ para todo β s-esparso. Mais forte.

(ii) **RE**: $\frac{1}{n}\|\boldsymbol{X}v\|^2 \geq \kappa\|v_S\|^2$ para v no cone $\mathcal{C}(S, c_0)$. Mais fraco que RIP; o LASSO força Δ para este cone naturalmente.

(iii) **Condição do Cone**: a desigualdade básica do LASSO força $\|\Delta_{S^c}\|_1 \leq 3\|\Delta_S\|_1$.

(iv) **IRC**: $\left\|\boldsymbol{X}_{S^c}^\top \boldsymbol{X}_S(\boldsymbol{X}_S^\top \boldsymbol{X}_S)^{-1}\right\|_\infty < 1$. Necessária para recuperação exata do suporte.

2.3. O LASSO

Definição: LASSO (Tibshirani, 1996)

$$\widehat{\beta}_{\text{lasso}} = \arg\min_{\beta}\left\{\frac{1}{2n}\|\boldsymbol{Y}-\boldsymbol{X}\beta\|_2^2 + \lambda\|\beta\|_1\right\}.$$

LASSO sob Design Ortogonal: Limiarização Suave

Se $\boldsymbol{X}^\top\boldsymbol{X} = n\boldsymbol{I}$:

$$\widehat{\beta}_j^{\text{lasso}} = S_\lambda(\widehat{\beta}_j^{\text{MQO}}), \qquad S_\lambda(z) = \text{sinal}(z)(|z|-\lambda)_+.$$

Demonstração

Sob design ortogonal, o objetivo se decompõe coordenada a coordenada: $\min_{\beta_j}\frac{1}{2}(\hat{\beta}_j^{\text{MQO}} - \beta_j)^2 + \lambda|\beta_j|$. A condição de otimalidade (subgradiente) para a j-ésima coordenada fornece exatamente $\widehat{\beta}_j = S_\lambda(\hat{\beta}_j^{\text{MQO}})$. $\square$

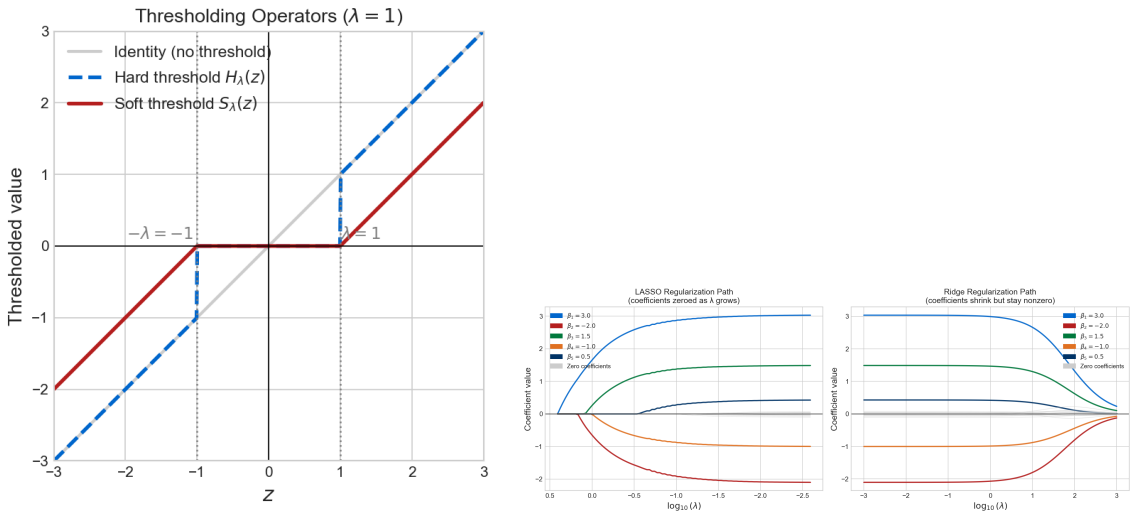

(a) Limiarização suave. (b) Caminhos de regularização.

Figura 2.1: (a) O operador $S_\lambda(z)$ anula coeficientes menores que λ em módulo. (b) Os coeficientes do LASSO atingem zero em λ finito (esparsidade); os da ridge se aproximam assintoticamente.

Por que ℓ_1 cria zeros mas ℓ_2 não? A bola ℓ_1 tem cantos nos eixos coordenados. Os elipsoides de nível da perda quadrática geralmente tangenciam esses cantos primeiro, produzindo soluções esparsas. A bola ℓ_2 é suave — a tangência nunca ocorre num canto.

2.3.1. Descida por Coordenadas

Inicializa $\beta^{(0)} = \mathbf{0}$. Itera: para $j = 1, \ldots, p$, compute o resíduo parcial $r_j = \boldsymbol{Y} - \sum_{k \neq j} x_k \beta_k$, então $\beta_j \leftarrow S_{n\lambda}(x_j^\top r_j / \|x_j\|^2)/(\|x_j\|^2/n)$. Convergência garantida pela convexidade do objetivo.

2.3.2. Teoria Estatística: Esparsidade e Taxas

Taxa do LASSO (Bickel, Ritov, Tsybakov, 2009)

Sob a condição de autovalor restrito e $\lambda = c\sigma\sqrt{\log p/n}$, com probabilidade $\geq 1 - 2/p$:

$$\left\|\widehat{\beta}_{\text{lasso}} - \beta^*\right\|_2 \leq \frac{4c\sigma}{\kappa}\sqrt{\frac{s \log p}{n}}.$$

Demonstração

Desigualdade básica. Como $\widehat{\beta}$ minimiza o objetivo e β^* é factível:

$$\frac{1}{2n}\left\|\boldsymbol{X}(\widehat{\beta} - \beta^*)\right\|^2 \leq \frac{1}{n}\varepsilon^\top \boldsymbol{X}\Delta + \lambda(\|\Delta_S\|_1 - \|\Delta_{S^c}\|_1), \quad \Delta = \widehat{\beta} - \beta^*.$$

Controle do ruído. Com probabilidade $\geq 1 - 2/p$: $\left\|\boldsymbol{X}^\top \varepsilon/n\right\|_\infty \leq \lambda$ (via desigualdade de Hoeffding + union bound). Isso força Δ ao cone restrito $\|\Delta_{S^c}\|_1 \leq 3\|\Delta_S\|_1$. **Aplicar RE.** $\kappa\|\Delta_S\|^2/2 \leq 2\lambda\sqrt{s}\|\Delta_S\|$, daí $\|\Delta\|_2 \leq 4\lambda\sqrt{s}/\kappa$. □

A Taxa $\sqrt{s \log p/n}$ e Sua Importância

O LASSO alcança erro de estimação $O(\sqrt{s \log p/n})$ em alta dimensão. O fator $\log p$ é o preço inevitável da seleção de modelos sobre p variáveis. Retornaremos a esta taxa na Aula 8, onde ela determina a validade da inferência do DML.

Exemplo: Aplicação: Estudos de Associação Genômica (GWAS)

Estudos genômicos tipicamente têm $n \approx 10.000$ indivíduos e $p \approx 500.000$ SNPs. Apenas alguns SNPs ($s \ll p$) estão verdadeiramente associados ao fenótipo. O LASSO identifica automaticamente essas associações esparsas, com λ escolhido por validação cruzada. A taxa $\sqrt{s \log p/n} \approx \sqrt{s \cdot 13/10.000}$ mostra que mesmo $n = 10.000$ pode recuperar um número moderado de sinais verdadeiros.

Aula 3

Árvores de Decisão e Florestas Aleatórias

Nota Histórica: De Árvores Isoladas a Florestas

Árvores de decisão têm raízes nas ciências sociais (Morgan & Sonquist, 1963) e na estatística (CART: Breiman, Friedman, Olshen & Stone, 1984). O bagging foi proposto por Breiman (1996); as florestas aleatórias pelo mesmo autor (2001) e tornaram-se um dos métodos mais amplamente usados na prática. A primeira prova rigorosa de consistência para o CART real foi de Scornet, Biau e Vert (2015), mais de uma década após a popularização do método.

3.1. Árvores de Decisão

Definição: Árvore de Regressão

Uma árvore particiona $\mathcal{X} \subseteq \mathbb{R}^p$ em M regiões retangulares $R_1, \ldots, R_M$ e prediz uma constante em cada uma:

$$\hat{f}(\boldsymbol{x}) = \sum_{m=1}^{M} \hat{c}_m \, \mathbb{1}[\boldsymbol{x} \in R_m], \qquad \hat{c}_m = \frac{1}{|R_m|} \sum_{x_i \in R_m} y_i.$$

Vantagens: interpretabilidade (fluxograma), invariância a escalonamento, lidam com variáveis categóricas e valores ausentes, captura de interações. **Desvantagem principal**: alta variância — pequenas perturbações nos dados produzem árvores completamente diferentes.

3.1.1. O Algoritmo CART

Definição: Critério de Divisão do CART (Regressão)

Em um nó com dados $\{(x_i, y_i) : i \in I\}$, encontre:

$$(j^*, s^*) = \arg\min_{j \in [p], s \in \mathbb{R}} \left[\sum_{i \in I : x_{ij} \leq s} (y_i - \hat{c}_L)^2 + \sum_{i \in I : x_{ij} > s} (y_i - \hat{c}_R)^2 \right].$$

Para classificação, substitua a soma de quadrados por impureza: **índice de Gini** $G(m) = \sum_k \hat{p}_{mk}(1 - \hat{p}_{mk})$ ou **entropia cruzada** $H(m) = -\sum_k \hat{p}_{mk} \log \hat{p}_{mk}$.

3.1.2. Desequilíbrio Viés–Variância em Árvores

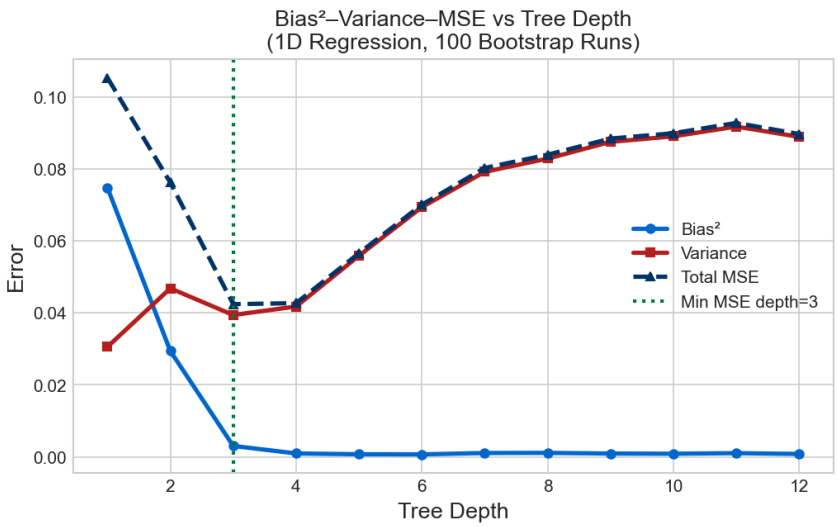

Figura 3.1: Viés ao quadrado, variância e EQM de teste vs. profundidade da árvore em um problema de regressão 1D. A variância cresce monotonicamente com a profundidade; o viés decresce.

Poda por Complexidade de Custo

Para uma subárvore $T \subseteq T_{\max}$:

$$C_\alpha(T) = \sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y_i - \hat{c}_m)^2 + \alpha |T|.$$

Breiman (1984) mostrou que o algoritmo "elo mais fraco" produz a sequência ótima $T_{\max} \supset T_1 \supset \cdots \supset T_0$ para todos os valores de α simultaneamente.

3.2. Métodos de Ensemble

Redução de Variância por Média

Seja $\hat{f}_1, \ldots, \hat{f}_B$ i.d. com correlação par-a-par ρ e variância individual σ^2:

$$\mathrm{Var}\left(\frac{1}{B}\sum_b \hat{f}_b\right) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2 \xrightarrow{B\to\infty} \rho\sigma^2.$$

Demonstração

$\mathrm{Var}\left(\frac{1}{B}\sum_b \hat{f}_b\right) = \frac{1}{B^2}\left[B\sigma^2 + B(B-1)\rho\sigma^2\right] = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$ □

O piso $\rho\sigma^2$ é irredutível por média. Para reduzi-lo, é preciso *descorrelacionar* as árvores — motivação para as florestas aleatórias.

3.3. Florestas Aleatórias

Definição: Algoritmo de Floresta Aleatória (Breiman, 2001)

Para $b = 1, \ldots, B$: amostre bootstrap $\mathcal{D}_b^* \sim \mathcal{D}$. Cresça árvore T_b em $\mathcal{D}_b^*$ com divisão: em cada nó, restrinja a busca a $m \leq p$ atributos aleatórios. Predição: $\hat{f}^{\mathrm{FA}}(x) = \frac{1}{B}\sum_b T_b(x)$.

O subconjunto de atributos (geralmente $m = \lfloor\sqrt{p}\rfloor$ para classificação) força cada árvore a usar atributos diferentes, reduzindo drasticamente ρ em relação ao bagging.

3.3.1. Erro Out-of-Bag

Cada bootstrap omite $\approx 36,8\%$ das observações — um conjunto de validação embutido:

$$\widehat{\mathrm{Err}}^{\mathrm{OOB}} = \frac{1}{n}\sum_i L\left(y_i, \frac{1}{|\mathcal{B}_i|}\sum_{b\in\mathcal{B}_i} T_b(x_i)\right), \qquad \mathcal{B}_i = \{b : i \notin \mathcal{D}_b^*\}.$$

Consistência das Florestas Aleatórias (Scornet, Biau & Vert, 2015)

Para modelos aditivos $f^*(x) = \sum_j f_j(x_j)$ com atributos independentes:

$$\mathbb{E}[(\hat{f}_n(x) - f^*(x))^2] \xrightarrow{n\to\infty} 0.$$

Esboço

Sob o modelo aditivo, cada coordenada é efetivamente um problema univariado. O estimador de floresta aleatória pode ser decomposto em estimadores de kernel univariados. Cada kernel tem largura de banda tendendo a zero (à medida que o mínimo de folhas $k_n \to \infty$ e $k_n/n \to 0$). Aplicam-se resultados padrão de consistência de regressão kernel. □

3.4. Overfitting Benigno e Dupla Descida

Nota Histórica: A Descoberta da Dupla Descida

A sabedoria clássica previa que o erro de teste cresce monotonicamente com a complexidade além de certo ponto. Em 2018–2019, Belkin, Hsu, Ma e Mandal observaram empiricamente que o erro de teste efetivamente *decresce novamente* além do limiar de interpolação $p = n$ — denominado *dupla descida*. Bartlett, Montanari e Rakhlin provaram este fenômeno rigorosamente para modelos lineares.

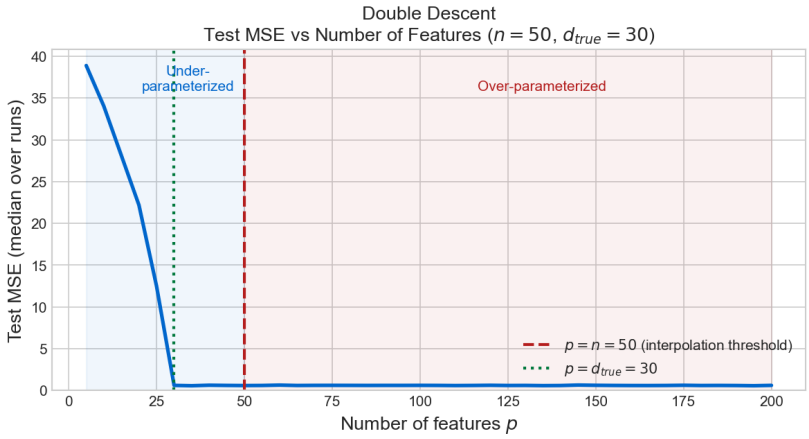

Figura 3.2: Curva de dupla descida: EQM de teste vs. dimensão p para regressão linear com $n = 50$. O pico em $p = n$ é o limiar de interpolação; para $p \gg n$, o interpolante de norma mínima tem viés e variância decrescentes.

Intuição. Quando $p \gg n$, há infinitas soluções interpolantes. O gradiente descendente converge ao *interpolante de norma ℓ_2 mínima* (pseudoinversa), que distribui o ajuste suavemente por muitas direções, evitando memorizar o ruído em qualquer direção específica. A dimensão efetiva da solução decresce, reduzindo a variância.

Definição: Rank Efetivo (Bartlett et al., 2020)

Sejam $\lambda_1 \geq \lambda_2 \geq \cdots$ os autovalores de $\boldsymbol{\Sigma} = \mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top]$. O **rank efetivo** além das k maiores componentes é: $r_k(\boldsymbol{\Sigma}) = \sum_{i>k} \lambda_i / \lambda_{k+1}$. Overfitting benigno requer r_k grande: a cauda do espectro é quase isotrópica, sem direção dominante, e o ruído se distribui uniformemente.

Regularização implícita. O gradiente descendente sem regularização explícita converge ao interpolante de norma mínima — uma forma de regularização *implícita*.

Aula 4

Redes Neurais e Teoria da Aproximação

Nota Histórica: Do Neurônio de McCulloch-Pitts ao Deep Learning

O neurônio artificial foi introduzido por McCulloch e Pitts (1943). A regra de Hebb (1949) forneceu um mecanismo de aprendizado local. O perceptron de Rosenblatt (1958) adicionou o primeiro teorema de convergência. A retropropagação foi descrita na tese de doutorado de Werbos (1974) e popularizada por Rumelhart, Hinton e Williams (1986). O deep learning explodiu em 2012 quando Krizhevsky, Sutskever e Hinton venceram o ImageNet por ampla margem. O Prêmio Nobel de Física de 2024 foi concedido a Hopfield e Hinton.

4.1. O Perceptron

Definição: Perceptron de Rosenblatt (1958)

$\hat{y}_i = \text{sinal}(\boldsymbol{w}^\top \boldsymbol{x}_i + b)$. Regra de aprendizado: se x_i é mal-classificado, $\boldsymbol{w} \leftarrow \boldsymbol{w} + \eta y_i \boldsymbol{x}_i$, $b \leftarrow b + \eta y_i$.

Teorema de Convergência do Perceptron

Se os dados são linearmente separáveis com margem $\gamma > 0$ e $\|x_i\| \leq R$, o perceptron converge em no máximo $T \leq (R/\gamma)^2$ erros.

Demonstração

Monitore: (a) $\boldsymbol{w}^{(T)\top} \boldsymbol{w}^* \geq T\gamma$ (cresce linearmente — cada atualização na direção correta adiciona pelo menos γ); (b) $\left\|\boldsymbol{w}^{(T)}\right\|^2 \leq TR^2$ (cresce no máximo linearmente — cada erro adiciona $\|y_i x_i\|^2 \leq R^2$, sendo o cruzamento não-positivo no erro). Por Cauchy-Schwarz: $T\gamma \leq \left\|\boldsymbol{w}^{(T)}\right\| \|\boldsymbol{w}^*\| \leq \sqrt{T}R$. Logo $T \leq (R/\gamma)^2$. $\square$

4.2. Perceptrons Multicamadas

Definição: Rede Neural Feedforward (MLP)

Profundidade L, larguras $n_0 = p, n_1, \ldots, n_L$:

$$\boldsymbol{z}^{(l)} = \boldsymbol{W}^{(l)}\boldsymbol{a}^{(l-1)} + \boldsymbol{b}^{(l)}, \quad \boldsymbol{a}^{(l)} = \sigma(\boldsymbol{z}^{(l)}), \quad l = 1, \ldots, L-1; \quad \hat{y} = \boldsymbol{W}^{(L)}\boldsymbol{a}^{(L-1)} + b^{(L)}.$$

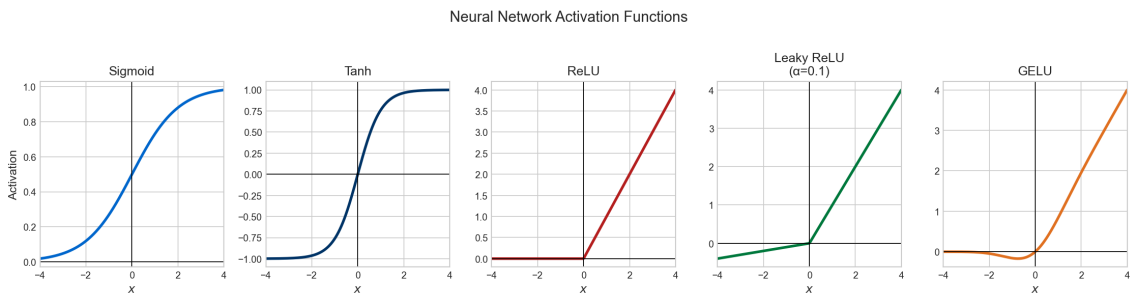

Figura 4.1: Cinco funções de ativação comuns. ReLU é o padrão do deep learning moderno. GELU (usado em Transformers) aproxima ReLU suavemente.

Problema da ReLU Morta: para $z < 0$, a ReLU tem saída e gradiente zero. Solução: Leaky ReLU $\max(\alpha z, z)$ ou GELU $z\Phi(z)$.

4.3. Retropropagação

O sinal de erro $\boldsymbol{\delta}^{(l)} = \partial\mathcal{L}/\partial\boldsymbol{z}^{(l)}$ satisfaz a recursão:

Retropropagação (Werbos 1974; Rumelhart et al. 1986)

Inicialize $\boldsymbol{\delta}^{(L)} = \nabla_{\hat{y}}\ell$. Para $l = L-1, \ldots, 1$:

$$\boldsymbol{\delta}^{(l)} = (\boldsymbol{W}^{(l+1)})^\top \boldsymbol{\delta}^{(l+1)} \odot \sigma'(\boldsymbol{z}^{(l)}).$$

Gradientes: $\nabla_{\boldsymbol{W}^{(l)}}\mathcal{L} = \boldsymbol{\delta}^{(l)}(\boldsymbol{a}^{(l-1)})^\top$, $\nabla_{\boldsymbol{b}^{(l)}}\mathcal{L} = \boldsymbol{\delta}^{(l)}$.

Demonstração

Pela regra da cadeia: $\delta_j^{(l)} = \sum_k \delta_k^{(l+1)} W_{kj}^{(l+1)} \sigma'(z_j^{(l)})$. Em forma matricial: $\boldsymbol{\delta}^{(l)} = (\boldsymbol{W}^{(l+1)})^\top \boldsymbol{\delta}^{(l+1)} \odot \sigma'(\boldsymbol{z}^{(l)})$. □

Gradientes que desaparecem. Para sigmoid: $\sigma'(z) \leq 1/4$. Após L camadas: $\left\|\boldsymbol{\delta}^{(1)}\right\| \lesssim (1/4)^{L-1}\left\|\boldsymbol{\delta}^{(L)}\right\| \to 0$. As camadas iniciais recebem sinal de gradiente essencialmente nulo.

4.4. Teoria da Aproximação

Teorema da Aproximação Universal (Cybenko 1989; Hornik et al. 1989)

Seja σ contínua, limitada e não-constante. Para qualquer $f \in C([0,1]^d)$ e $\varepsilon > 0$, existe N e pesos tais que $\sup_x |f(x) - \sum_j c_j \sigma(w_j^\top x + b_j)| < \varepsilon$.

Demonstração construtiva para $d = 1$ (Cybenko, 1989)

Passo 1. **Função degrau**: $\sigma(w(x-c))$ com $c = -b/w$. Quando $w \to \infty$, $\sigma(w(x-c))$ torna-se $\mathbb{1}[x \geq c]$, saltando de 0 a 1 em c.

Passo 2. **Indicadora de intervalo**: $B(x) = \sigma(w(x-c_1)) - \sigma(w(x-c_2))$ no intervalo $[c_1, c_2]$. Para $w \to \infty$: $B(x) \approx \mathbb{1}[x \in [c_1, c_2]]$.

Passo 3. **Constante por partes**: particionar $[0,1]$ em intervalos e aproximar $f(x) \approx \sum_k f(x_k) B_k(x)$.

Passo 4. **Rede de camada única**: $g(x) = \sum_k f(x_k)[\sigma(w(x-c_k)) - \sigma(w(x-c_{k+1}))]$ com $2K$ neurônios sigmoid.

□

Esboço não-construtivo (Hahn-Banach)

Suponha que tal rede não existe. Pelo teorema de Hahn-Banach, existe $\mu \neq 0$ tal que $\int \sigma(\boldsymbol{w}^\top \boldsymbol{x} + b)\, d\mu(\boldsymbol{x}) = 0$ para todos $\boldsymbol{w}, b$. Mostra-se que a transformada de Fourier de μ se anula identicamente, forçando $\mu = 0$ — contradição. □

Teorema de Barron (1993) — Taxa Livre de Dimensão

Se $C_f = \int \|\boldsymbol{\omega}\|\, |\hat{f}(\boldsymbol{\omega})|\, d\boldsymbol{\omega} < \infty$ (norma espectral), então para qualquer $N \geq 1$:

$$\inf_{f_N \in \mathcal{F}_N} \int (f - f_N)^2\, d\mu \leq \frac{C_f^2}{N},$$

onde $\mathcal{F}_N$ é a classe de redes de camada única com N neurônios sigmoid.

Método probabilístico

Escreva $f(x) = C_f \mathbb{E}_{\boldsymbol{\omega} \sim \pi}[g_{\boldsymbol{\omega}}(x)]$ onde π tem densidade $|\hat{f}|/C_f$ e $g_{\boldsymbol{\omega}}$ é limitada. A média empírica $f_N = C_f \frac{1}{N} \sum_j g_{\boldsymbol{\omega}_j}$ (com $\boldsymbol{\omega}_j \sim \pi$ i.i.d.) satisfaz $\mathbb{E} \int (f - f_N)^2\, d\mu = C_f^2\, \mathrm{Var}_\pi(g)/N \leq C_f^2/N$. □

Por que é notável? A taxa $O(1/N)$ é *livre de dimensão*: não depende de d. Em contraste, a aproximação polinomial em $\mathbb{R}^d$ com N termos atinge apenas $O(N^{-2k/d})$ para funções k-suaves — maldição da dimensionalidade.

Aula 5

Inferência Variacional, VAEs e Dinâmica de Langevin

Nota Histórica: As Origens da Inferência Variacional

A ideia de aproximar distribuições intratáveis por otimização tem raízes na física estatística (teoria de campo médio para o modelo de Ising, Peierls 1936). A formalização em aprendizado de máquina veio com Jordan, Ghahramani, Jaakkola e Saul (1999). Blei, Kucukelbir e McAuliffe (2017) forneceram o tratamento algorítmico moderno. O autoencoder variacional (Kingma & Welling, 2013) trouxe a modelagem generativa com variáveis latentes para a era do deep learning.

5.1. De Predição à Modelagem Generativa

Modelos probabilísticos/generativos vão além da predição: aprendem a distribuição conjunta completa $p(x)$ ou $p(x, z)$.

Modelos de variáveis latentes: $z \sim p(z)$ (prior), $x|z \sim p_\theta(x|z)$ (verossimilhança). A marginal $p_\theta(x) = \int p_\theta(x|z)p(z)\,dz$ é frequentemente intratável.

5.2. Entropia e Divergência KL

Definição: Entropia de Shannon

$H(p) = -\mathbb{E}_p[\log p(X)]$. Mede a incerteza média em p. Maximizada pela uniforme; zero para massa pontual.

Definição: Divergência KL

$\mathrm{KL}(p\|q) = \mathbb{E}_p[\log p(X)/q(X)]$.

Desigualdade de Gibbs

$\mathrm{KL}(p\|q) \geq 0$, com igualdade sse $p = q$ q.c.

Demonstração

Por Jensen e concavidade do log: $-\mathrm{KL}(p\|q) = \mathbb{E}_p[\log(q/p)] \leq \log \mathbb{E}_p[q(X)/p(X)] = \log 1 = 0$. □

KL direta vs. reversa. A KL direta $\min_q \mathrm{KL}(p\|q)$ é cobridora de massa (exige que q cubra todos os modos de p). A KL reversa $\min_q \mathrm{KL}(q\|p)$ é buscadora de modos (concentra q em um modo de p). A IV minimiza a KL reversa — mais tratável (amostras de q disponíveis), mas causa *colapso de modo*.

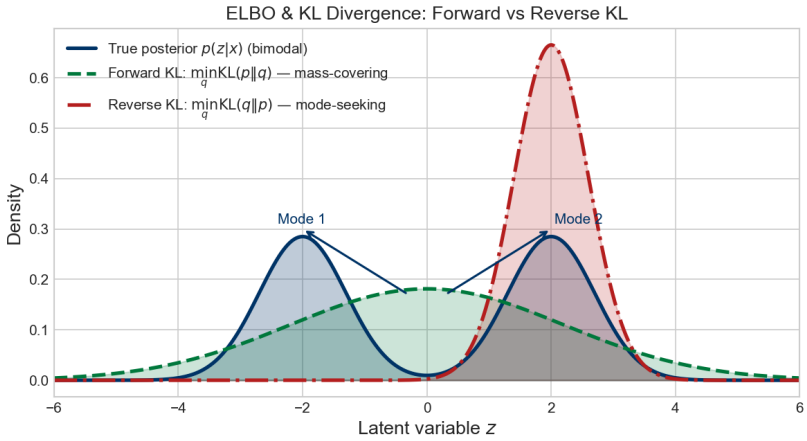

Figura 5.1: KL direta vs. reversa em um alvo bimodal $p(z|x)$. A KL direta produz aproximação cobridora e ampla; a KL reversa produz aproximação buscadora de modo e estreita.

5.3. O Limitante Inferior da Evidência (ELBO)

Decomposição ELBO

Para qualquer $q(z)$:

$$\log p_\theta(x) = \underbrace{\mathbb{E}_q[\log p_\theta(x,z)/q(z)]}_{\mathcal{L}} + \underbrace{\mathrm{KL}(q\|p_\theta(\cdot|x))}_{\geq 0}.$$

Portanto $\mathcal{L} \leq \log p_\theta(x)$, com igualdade sse $q = p_\theta(\cdot|x)$.

Demonstração

$\log p_\theta(x) = \log \mathbb{E}_q[p_\theta(x,z)/q(z)] \geq \mathbb{E}_q[\log p_\theta(x,z)/q(z)] = \mathcal{L}$ pela desigualdade de Jensen (o log é côncavo). O gap é $\mathrm{KL}(q\|p_\theta(\cdot|x)) \geq 0$ pela desigualdade de Gibbs. □

Derivação alternativa via Bayes (das notas de mão)

$\log p_\theta(x) = \int q(z) \log p_\theta(x)\, dz$. Usando Bayes: $p_\theta(x) = p_\theta(x,z)/p_\theta(z|x)$:

$$\log p_\theta(x) = \int q(z) \log \frac{p_\theta(x,z)}{q(z)} \cdot \frac{q(z)}{p_\theta(z|x)}\, dz = \underbrace{\int q(z) \log \frac{p_\theta(x,z)}{q(z)}\, dz}_{\mathcal{L}} + \underbrace{\mathrm{KL}(q \| p_\theta(\cdot|x))}_{\geq 0}.$$

Derivação exata (sem Jensen). O gap é transparente: $= \mathrm{KL}(q \| p_\theta(\cdot|x))$. □

Forma equivalente: $\mathcal{L} = \underbrace{\mathbb{E}_q[\log p_\theta(x|z)]}_{\text{reconstrução}} - \underbrace{\mathrm{KL}(q\|p)}_{\text{regularização}}$.

5.4. Inferência Variacional

A IV transforma a inferência Bayesiana intratável em otimização: $q^* = \arg\max_{q \in \mathcal{Q}} \mathcal{L}(\theta, q; x)$.

5.4.1. Campo Médio e CAVI

A aproximação de **campo médio** assume $q(z) = \prod_j q_j(z_j)$.

Fator Ótimo de Campo Médio

$q_j^*(z_j) \propto \exp(\mathbb{E}_{q_{-j}}[\log p(x,z)])$.

Demonstração

$\mathcal{L}|_{q_j} = \mathbb{E}_{q_j}[\log \tilde{p}_j(z_j)] - \mathbb{E}_{q_j}[\log q_j(z_j)] + \text{cte} = -\mathrm{KL}(q_j \| \tilde{p}_j) + \text{cte}$, onde $\tilde{p}_j(z_j) \propto \exp(\mathbb{E}_{q_{-j}}[\log p(x,z)])$. Maximizado quando $q_j = \tilde{p}_j$. □

Algoritmo CAVI: inicializa todos os q_j, itera atualizando cada q_j ao seu ótimo com os demais fixos, até convergência do ELBO.

5.5. Autoencoder Variacional (VAE)

Definição: Modelo VAE (Kingma & Welling, 2013)

Prior: $p(z) = \mathcal{N}(\mathbf{0}, \boldsymbol{I})$. Decodificador: $p_\theta(x|z) = \mathcal{N}(\mu_\theta(z), \sigma^2 \boldsymbol{I})$. Codificador: $q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \mathrm{diag}(\sigma_\phi^2(x)))$.

KL em Forma Fechada para Gaussianas Diagonais

$\mathrm{KL}(q_\phi \| \mathcal{N}(\mathbf{0}, \boldsymbol{I})) = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2)$.

Demonstração

Para $q = \mathcal{N}(\mu, \sigma^2)$, $p = \mathcal{N}(0,1)$: $\mathrm{KL}(q\|p) = \mathbb{E}_q[-\frac{(z-\mu)^2}{2\sigma^2} + \frac{z^2}{2} + \log\frac{1}{\sigma}] = \frac{1}{2}(\mu^2 + \sigma^2 - 1 - \log\sigma^2)$. Somando sobre k dimensões independentes. □

5.5.1. O Truque da Reparametrização

Para diferenciar $\mathbb{E}_{q_\phi}[\cdot]$ em relação a ϕ: escreva $z = \mu_\phi(x) + \sigma_\phi(x) \odot \xi$, $\xi \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$. Agora z é função determinística de ϕ e o gradiente flui normalmente pela retropropagação.

Exemplo: Aplicação: Descoberta de Medicamentos com VAEs

Gómez-Bombarelli et al. (2018) aplicaram um VAE a moléculas codificadas como SMILES. O codificador mapeia moléculas a um espaço latente contínuo; o decodificador gera novos SMILES. Otimização Bayesiana no espaço latente suave explora o espaço químico eficientemente, descobrindo moléculas com propriedades desejadas (semelhança a medicamentos, afinidade de ligação).

5.6. Dinâmica de Langevin

Definição: Dinâmica de Langevin (Algoritmo)

Para amostrar de $p(x) \propto e^{-U(x)}$:

$$x_{t+1} = x_t + \eta\nabla_x \log p(x_t) + \sqrt{2\eta}\varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I}).$$

O passo $\eta\nabla \log p$ move em direção às regiões de alta densidade; o ruído $\sqrt{2\eta}\varepsilon_t$ garante exploração. No limite $\eta \to 0$, converge para p.

Convergência do ULA (Dalalyan, 2017)

Assuma $p(x) \propto e^{-U(x)}$ com U L-suave e m-fortemente convexo. Com passo $\eta \leq 2/(m+L)$:

$$W_2(p_{x_T}, p) \leq (1 - m\eta)^T W_2(p_{x_0}, p) + C\sqrt{d\eta}.$$

Para atingir $W_2 \leq \varepsilon$: $\eta = O(\varepsilon^2/d)$, $T = O((L/m)\log(1/\varepsilon))$.

Conexão com modelos generativos por score. Se estimamos $s(x) = \nabla_x \log p(x)$ sem conhecer $p(x)$ (via rede neural), podemos rodar Langevin para amostrar de p. A ponte de Langevin (Aula 5) para DDPM e Flow Matching (Aula 6) passa por esta ideia: treinar $s_\phi(x) \approx \nabla_x \log p_{\text{dados}}(x)$ e usar ULA para gerar amostras.

Aula 6

Modelos de Difusão e Flow Matching

Nota Histórica: O Caminho até os Modelos Generativos Modernos

Os GANs (Goodfellow et al., 2014) iniciaram a modelagem generativa profunda, mas sofriam de instabilidade e colapso de modo. Os VAEs eram estáveis mas produziam amostras borradas. O avanço veio com o score matching (Hyvärinen, 2005) e o DSM (Vincent, 2011), que Song e Ermon (2019) escalaram para imagens. Ho et al. (2020) mostraram que o mesmo framework, como VAE hierárquico (DDPM), alcançava qualidade sem precedentes. Song et al. (2021) unificaram o framework via EDEs estocásticas. O Flow Matching (Lipman et al., 2022) forneceu uma perspectiva baseada em EDOs mais simples.

6.1. DDPM: Modelos Probabilísticos de Difusão com Denoisificação

6.1.1. O Processo Direto

DDPM (Ho et al., 2020) define uma cadeia de Markov que destrói gradualmente os dados:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_{t-1}, (1-\alpha_t)\boldsymbol{I}), \quad \alpha_t = 1 - \beta_t.$$

Marginal em Forma Fechada

Com $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$: $q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\boldsymbol{I})$. Equivalentemente: $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\varepsilon$, $\varepsilon \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$.

Demonstração

Por indução. Base: $q(x_1|x_0) = \mathcal{N}(\sqrt{\alpha_1}x_0, (1-\alpha_1)\boldsymbol{I})$. Passo: pela fórmula de soma de Gaussianas, $q(x_t|x_0) = \mathcal{N}(\sqrt{\alpha_t\bar{\alpha}_{t-1}}x_0, (\alpha_t(1-\bar{\alpha}_{t-1}) + (1-\alpha_t))\boldsymbol{I}) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\boldsymbol{I})$. $\square$

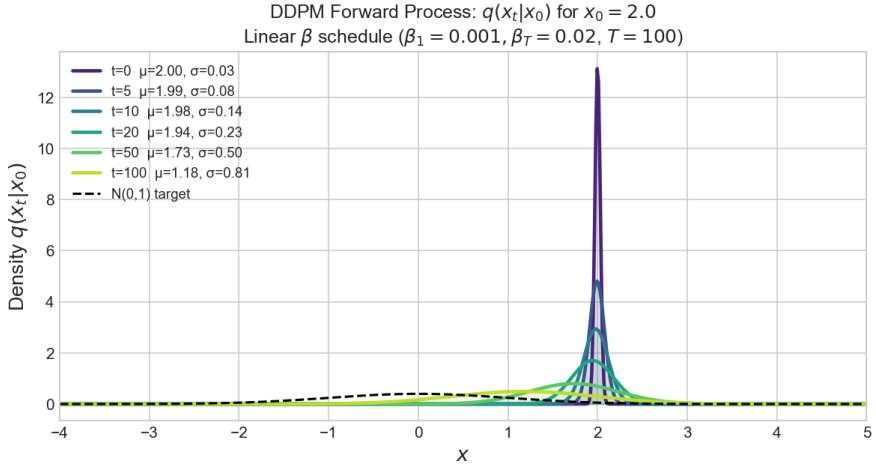

Figura 6.1: Processo de difusão direta: a distribuição $q(x_t|x_0)$ para $x_0 = 2$ torna-se progressivamente mais larga e centrada em zero. Em $t = T$, o sinal é destruído e $q(x_T|x_0) \approx \mathcal{N}(0, 1)$.

6.1.2. Processo Reverso e Objetivo de Treino

Posterior Verdadeiro do Processo Reverso

Condicionando em x_0: $q(x_{t-1}|x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t, \tilde{\beta}_t \boldsymbol{I})$ em forma fechada.

Demonstração

Pelo teorema de Bayes: $q(x_{t-1}|x_t, x_0) \propto q(x_t|x_{t-1})q(x_{t-1}|x_0)$. Ambas são gaussianas; o produto das exponenciais é quadrático em x_{t-1}, dando uma Gaussiana. Completando o quadrado obtemos $\tilde{\mu}_t$ e $\tilde{\beta}_t$. □

Perda Simplificada do DDPM

$$\mathcal{L}_{\text{simples}}(\theta) = \mathbb{E}_{t,x_0,\varepsilon}\left[\left\|\varepsilon - \varepsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\varepsilon, t)\right\|^2\right].$$

A rede é um *detetive de ruído*: dado x_t no nível t, prediz o ruído ε que foi adicionado.

6.2. Score Matching

Definição: Função Score

$s(x) = \nabla_x \log p(x)$. Para modelos baseados em energia $p_\phi(x) \propto e^{-E_\phi(x)}$: $\nabla_x \log p_\phi(x) = -\nabla_x E_\phi(x)$ (a constante de partição se cancela).

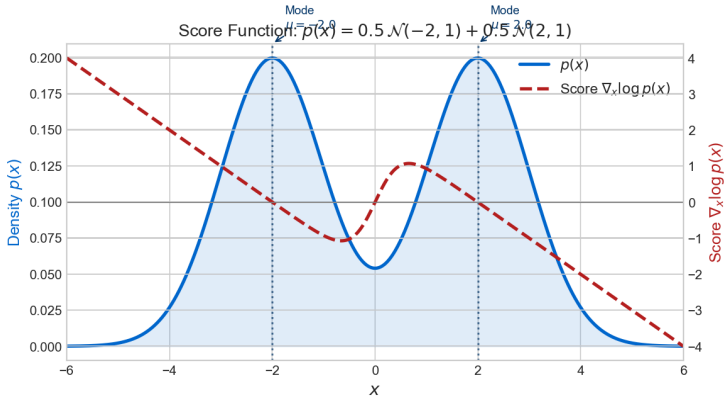

Figura 6.2: Função score de $p(x) = 0.5\mathcal{N}(-2,1) + 0.5\mathcal{N}(2,1)$. O score (vermelho) aponta para os dois modos; a dinâmica de Langevin seguindo este campo converge para amostras de p.

Score Matching com Denoisificação — DSM (Vincent, 2011)

Perturbe: $\tilde{x} = x + \sigma\varepsilon$. O score condicional é $\nabla_{\tilde{x}} \log p_\sigma(\tilde{x}|x) = -\varepsilon/\sigma$. A perda DSM $\mathcal{L}_{\text{DSM}}(\phi;\sigma) = \frac{1}{2}\mathbb{E}\,\|s_\phi(\tilde{x};\sigma) + \varepsilon/\sigma\|^2$ tem o mesmo minimizador que o score matching original, sem necessitar do score verdadeiro.

Demonstração

$\mathcal{L}_{\text{DSM}} = \frac{1}{2}\mathbb{E}\,\|s_\phi(\tilde{x}) - \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}|x)\|^2$. Expandindo e integrando em x: $= \frac{1}{2}\mathbb{E}\,\|s_\phi(\tilde{x}) - \nabla \log p_\sigma(\tilde{x})\|^2 + \text{cte}$ — igual ao objetivo de score matching original a menos de uma constante. □

6.3. Flow Matching

Definição: Flow Matching / Fluxo Normalizado Contínuo

Encontre $v_\phi : \mathcal{X} \times [0,1] \to \mathcal{X}$ tal que integrar $\frac{dx(t)}{dt} = v_\phi(x(t),t)$ transporte amostras de $p_0 = \mathcal{N}(\mathbf{0}, \boldsymbol{I})$ em $t = 0$ para $p_1 = p_{\text{dados}}$ em $t = 1$.

Flow Matching Condicional (CFM)

Defina caminhos condicionais $p_t(x|z)$ com velocidade de forma fechada $v_t(x|z)$. A perda CFM:

$$\mathcal{L}_{\text{CFM}}(\phi) = \mathbb{E}_{t,z,x\sim p_t(\cdot|z)}\,\|v_\phi(x,t) - v_t(x|z)\|^2$$

tem o mesmo gradiente que a perda FM marginal intratável.

Demonstração

$\mathcal{L}_{\text{FM}} - \mathcal{L}_{\text{CFM}} = \mathbb{E}_{t,x}[\|v_t(x)\|^2 - \|\mathbb{E}[v_t(x|z)|x]\|^2]$, que não depende de ϕ. Logo $\nabla_\phi \mathcal{L}_{\text{FM}} = \nabla_\phi \mathcal{L}_{\text{CFM}}$. □

Caminhos Gaussianos. $x_t = (1-t)x_0 + tx_1$ com $v_t(x_t|x_0, x_1) = x_1 - x_0$ (constante). Perda CFM Gaussiana: prever simplesmente a direção $x_1 - x_0$!

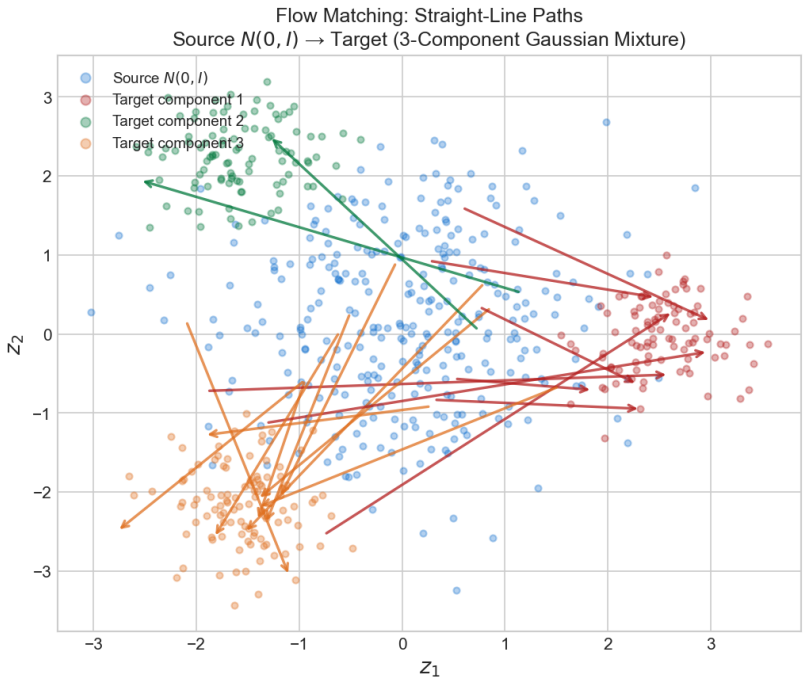

Figura 6.3: Flow Matching Gaussiano: 20 caminhos lineares de $\mathcal{N}(\mathbf{0}, \boldsymbol{I})$ a uma mistura de 3 Gaussianas. Cada caminho tem velocidade constante $x_1 - x_0$; nenhuma simulação de EDO é necessária durante o treino.

Aula 7

Inferência Causal

Nota Histórica: Uma Breve História da Inferência Causal

A matemática da causalidade tem duas tradições paralelas. O framework de **resultados potenciais** origina-se com Neyman (1923) e foi desenvolvido por Rubin (1974). A abordagem **gráfica/estrutural** foi desenvolvida por Wright (1921), Haavelmo (1944) e Pearl (1988–2009) com DAGs e do-cálculo. As duas tradições são matematicamente equivalentes sob SUTVA.

7.1. Por Que Causalidade Não se Reduz a Correlação

ML padrão minimiza $\mathbb{E}[\ell(f(X), Y)]$ — correto para predição sob a *mesma* distribuição. Questões causais requerem mais: $P(Y|\text{do}(X = x))$ vs. $P(Y|X = x)$.

Exemplos de confusão: hospitais têm maior mortalidade (pacientes mais doentes são internados — viés de seleção); "paciente em UTI prediz baixa mortalidade" observacionalmente, mas enviar pacientes à UTI *reduz* a mortalidade causalmente.

7.2. A Escada da Causalidade de Pearl

Três Degraus da Causalidade (Pearl, 2009)

Degrau 1. Associação: $P(Y|X = x)$ — estatística pura, respondível apenas com dados.
Degrau 2. Intervenção: $P(Y|\text{do}(X = x))$ — requer suposições estruturais.
Degrau 3. Contrafactual: $P(Y_{x'}|X = x, Y = y)$ — requer um SCM completo.
Resultado chave: Nenhuma quantidade de dados sozinha pode escalar a escada.

7.3. Framework de Resultados Potenciais

Definição: Resultados Potenciais (Rubin, 1974)

$Y_i(1)$: resultado se i recebe tratamento. $Y_i(0)$: sem tratamento. $\tau_i = Y_i(1) - Y_i(0)$: efeito individual. Observado: $Y_i^{\text{obs}} = T_i Y_i(1) + (1 - T_i) Y_i(0)$.

O Problema Fundamental da Inferência Causal (Holland, 1986)

$Y_i(1 - T_i)$ é contrafactual — nunca observado. Não é possível calcular τ_i para qualquer indivíduo diretamente.

Identificação sob Ignorabilidade + Sobreposição

Com (i) $\{Y(0), Y(1)\} \perp\!\!\!\perp T|X$ e (ii) $0 < P(T = 1|X = x) < 1$:

$$\text{ATE} = \mathbb{E}_X[\mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]].$$

Demonstração

$\mathbb{E}[Y(t)|X = x] = \mathbb{E}[Y(t)|T = t, X = x]$ (ignorabilidade) $= \mathbb{E}[Y^{\text{obs}}|T = t, X = x]$ (consistência). Integrando em X dá o ATE. $\square$

7.4. Modelos Causais Estruturais e DAGs

Definição: SCM

Equações estruturais $X_i := f_i(\text{Pa}(X_i), U_i)$. Grafo: $X_j \to X_i$ sse $X_j \in \text{Pa}(X_i)$. Fatoração de Markov: $P(X_1, \ldots, X_p) = \prod_i P(X_i|\text{Pa}(X_i))$.

Três padrões elementares de caminho:

- **Cadeia** $X \to Z \to Y$: $X \not\perp\!\!\!\perp Y$ marginalmente; $X \perp\!\!\!\perp Y|Z$ (condicionamento bloqueia).
- **Garfo** $X \leftarrow Z \to Y$: $X \not\perp\!\!\!\perp Y$ marginalmente; $X \perp\!\!\!\perp Y|Z$ (Z é confundidor).
- **Colisor** $X \to Z \leftarrow Y$: $X \perp\!\!\!\perp Y$ marginalmente; $X \not\perp\!\!\!\perp Y|Z$ (condicionamento *abre* o caminho — viés de colisor).

Exemplo: Paradoxo de Berkson / Viés de Colisor

Entre pacientes hospitalizados (condicionando em $Z = 1$), gravidade de doença X e gravidade de acidente Y são negativamente correlacionados, mesmo sendo independentes na população. Para ser hospitalizado, um paciente precisa de doença grave OU acidente grave — colisor.

d-Separação (Pearl, 1988)

Um caminho π é bloqueado por Z se: (i) contém cadeia ou garfo com nó $M \in Z$; ou (ii) contém colisor $A \to M \leftarrow B$ com $M \notin Z$ e nenhum descendente de M em Z. Sob fidelidade: $X \perp_G Y|Z \iff X \perp\!\!\!\perp_P Y|Z$.

Critério Backdoor (Pearl, 1993)

Z satisfaz o critério backdoor relativo a (X, Y) se: (i) nenhum nó em Z é descendente de X; (ii) Z bloqueia todos os caminhos backdoor de X para Y. Então: $P(Y|\text{do}(X = x)) = \sum_z P(Y|X = x, Z = z)P(Z = z)$.

Esboço

O operador do-$(X = x)$ remove todas as arestas entrando em X, criando o grafo mutilado $G_{\bar{X}}$. Na fatoração truncada, $P(Z|\text{do}(X = x)) = P(Z)$ pois Z não é descendente de X e remover as arestas de X não afeta Z. □

7.5. Variáveis Instrumentais

Quando há confundidor não-observado U em $T \leftarrow U \rightarrow Y$, não se pode bloquear o caminho backdoor condicionando em variáveis observadas.

Definição: Instrumento Válido

Z é instrumento válido para o efeito de T em Y se: (i) Relevância: $\text{Cov}(Z, T) \neq 0$; (ii) Exclusão: $Z \rightarrow Y$ apenas através de T; (iii) Independência: $Z \perp\!\!\!\perp U$.

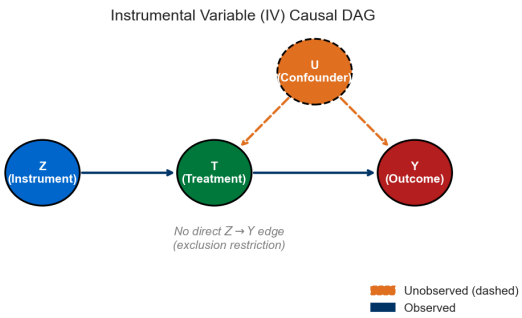

Figura 7.1: DAG de variável instrumental. Z (instrumento) não tem caminho direto para Y e é independente do confundidor não-observado U (tracejado).

Estimador de Wald e LATE (Angrist, Imbens & Rubin, 1996)

Para Z binário: $\hat{\beta}_{\text{VI}} = \frac{\mathbb{E}[Y|Z=1]-\mathbb{E}[Y|Z=0]}{\mathbb{E}[T|Z=1]-\mathbb{E}[T|Z=0]} \xrightarrow{p} \text{LATE} = \mathbb{E}[Y(1) - Y(0)|\text{cumpridor}]$, sob relevância, exclusão, independência e monotonicidade ($T_i(Z = 1) \geq T_i(Z = 0)$ para todo i).

Demonstração

Pela exclusão: $\mathbb{E}[Y|Z = 1] - \mathbb{E}[Y|Z = 0] = \mathbb{E}[Y(T(1)) - Y(T(0))]$. Sob monotonicidade (sem defensores): $= \mathbb{E}[Y(1) - Y(0)|\text{cumpridor}] \cdot P(\text{cumpridor})$. O denominador $= P(\text{cumpridor})$. A divisão dá o LATE. □

Exemplo: Loteria do Draft como Instrumento

Angrist (1990) usou a loteria do recrutamento da Guerra do Vietnã como instrumento para o serviço militar. Z = número da loteria (aleatório), T = serviço militar, Y = renda futura. A loteria é relevante, satisfaz exclusão e é independente dos confundidores (foi aleatorizada). A estimativa IV mostrou que o serviço militar reduziu a renda civil.

7.6. Descoberta Causal: Algoritmo PC

Definição: Algoritmo PC (Spirtes, Glymour & Scheines, 1993)

Passo 1: Comece com grafo completo não-direcionado. Para cada par (X_i, X_j) e conjunto S: teste $X_i \perp\!\!\!\perp X_j | S$. Se independentes, remova a aresta. **Passo 2**: Oriente v-estruturas (colisores). **Passo 3**: Aplique regras de Meek para orientar arestas restantes.

Sob fidelidade, o PC recupera o CPDAG (classe de equivalência de Markov) do DAG verdadeiro com probabilidade tendendo a 1.

Aula 8

Double Machine Learning

Nota Histórica: Da Econometria ao DML

Robinson (1988) introduziu o modelo parcialmente linear e provou que inferência $\sqrt{n}$-consistente sobre θ_0 é possível mesmo com estimação não-paramétrica da nuisância, desde que as taxas sejam suficientemente rápidas. A formulação moderna com ortogonalização explícita e validação cruzada é de Chernozhukov et al. (2018), combinando a decomposição de Robinson com a ortogonalidade de Neyman (1959) e a divisão amostral de Schick (1986).

8.1. O Problema: Controles de Alta Dimensão com Inferência Válida

Exemplo: Elegibilidade ao 401(k) e Poupança

Y = ativos financeiros líquidos, D = elegibilidade ao 401(k), X = renda, idade, escolaridade, tamanho familiar, estado civil, IRA ($p > 100$). Trabalhadores elegíveis diferem sistematicamente — ajustamento para X é necessário, mas p pode exceder n.

8.2. O Modelo Parcialmente Linear

Definição: MPL (Robinson, 1988)

$Y_i = \theta_0 D_i + g_0(X_i) + \varepsilon_i$, $\mathbb{E}[\varepsilon_i | D_i, X_i] = 0$.

Falha do plug-in ingênuo. Substituindo $g_0 \to \hat{g}$ (ML) e tomando MQO: $\sqrt{n}(\hat{\theta}^{\text{ing}} - \theta_0) = a + b$, onde $|b| = O_{\mathbb{P}}(n^{1/4}) \to \infty$. O viés domina; os ICs têm cobertura $\to 0$.

8.3. Decomposição de Robinson e Partialling-Out

Defina $m_0(x) = \mathbb{E}[D|X = x]$, $\ell_0(x) = \mathbb{E}[Y|X = x]$. Subtraindo as expectativas condicionais:

$$\underbrace{Y_i - \ell_0(X_i)}_{\widetilde{Y}_i} = \theta_0 \underbrace{(D_i - m_0(X_i))}_{V_i} + \varepsilon_i.$$

A nuisância g_0 foi completamente eliminada!

Equação de Robinson

$\widetilde{Y}_i = \theta_0 V_i + \varepsilon_i$. Se m_0, ℓ_0 fossem conhecidas: $\hat{\theta}^{\text{oráculo}} = \mathbb{E}_n[V_i \widetilde{Y}_i]/\mathbb{E}_n[V_i^2]$ é $\sqrt{n}$-consistente e assintoticamente normal.

8.4. A Solução DML

8.4.1. De $a + b$ a $a^* + b^* + c^*$

O estimador DML usa $\hat{V}_i = D_i - \hat{m}(X_i)$. O erro escalado: $\sqrt{n}(\hat{\theta}^{\text{DML}} - \theta_0) = a^* + b^* + c^*$, onde b^* é produto de dois erros de ML.

A Diferença Estrutural

	Ingênuo	**DML**
Termo ruim	$D_i \cdot (\hat{g} - g_0)$	$\hat{m}_i \cdot \hat{\ell}_i$
Taxa	$O_{\mathbb{P}}(n^{-1/4})$	$O_{\mathbb{P}}(n^{-1/2})$
Desaparece?	Não	Sim

$|b^*| \leq \sqrt{n}\, \|\hat{m} - m_0\| \left\|\hat{\ell} - \ell_0\right\| = \sqrt{n} \cdot O_{\mathbb{P}}(n^{-1/4}) \cdot O_{\mathbb{P}}(n^{-1/4}) = o_{\mathbb{P}}(1)$.

8.4.2. Ingrediente 1: Ortogonalidade de Neyman

Definição: Ortogonalidade de Neyman

Um score $\psi(W; \theta, \eta)$ é ortogonal se $\partial_\eta \mathbb{E}[\psi(W; \theta_0, \eta_0)][\delta\eta] = 0$ para todo $\delta\eta$. Erros em $\hat{\eta}$ afetam $\hat{\theta}$ apenas em segunda ordem.

Ortogonalidade do Score do MPL

O score DML $\psi^{\text{DML}} = (\widetilde{Y}_i - \theta V_i) \cdot V_i$ é ortogonal: perturbações em $\hat{\ell}$ e $\hat{m}$ se anulam em primeira ordem.

Demonstração

Perturbar ℓ: $\partial_\ell \mathbb{E}[\psi][\delta\ell] = -\mathbb{E}[\delta\ell(X) \cdot V] = -\mathbb{E}[\delta\ell(X) \cdot \mathbb{E}[V|X]] = 0$ (pois $\mathbb{E}[V|X] = 0$).
Perturbar m: $\partial_m \mathbb{E}[\psi][\delta m] = -\theta\mathbb{E}[\delta m \cdot V] + \mathbb{E}[\varepsilon \cdot \delta m(X)] = 0 + \mathbb{E}[\delta m(X) \underbrace{\mathbb{E}[\varepsilon|X]}_{=0}] = 0$.

□

8.4.3. Ingrediente 2: Validação Cruzada (Cross-Fitting)

Definição: Cross-Fitting em K Folds

Divida em K folds. Para cada fold k: treine $\hat{m}_{-k}, \hat{\ell}_{-k}$ em I_k^c. Prediga resíduos $\hat{V}_i, \hat{\tilde{Y}}_i$ para $i \in I_k$. Agregue todos os folds para $\hat{\theta}^{\text{DML2}}$.

O cross-fitting garante $\hat{m}_{-k}(X_i) \perp\!\!\!\perp \varepsilon_i$ — o termo cruzado se anula: $\mathbb{E}[(\hat{m}_{-k}(X_i) - m_0(X_i))\varepsilon_i | S_{-k}] = 0$.

Teorema DML Principal (Chernozhukov et al., 2018)

Sob o MPL, não-confundimento e $\|\hat{m} - m_0\| \left\|\hat{\ell} - \ell_0\right\| = o_{\mathbb{P}}(n^{-1/2})$:

$$\sqrt{n}(\hat{\theta}^{\text{DML}} - \theta_0) \xrightarrow{d} N(0, \Sigma), \quad \Sigma = (\mathbb{E}[V^2])^{-1}\mathbb{E}[V^2\varepsilon^2](\mathbb{E}[V^2])^{-1}.$$

IC 95% válido: $\hat{\theta} \pm 1{,}96\hat{\sigma}/\sqrt{n}$.

Esboço

Após cross-fitting: $\sqrt{n}(\hat{\theta} - \theta_0) = a^* + b^* + c^*$. $b^* = o_{\mathbb{P}}(1)$: por Cauchy-Schwarz e a condição de taxa. $c^* = o_{\mathbb{P}}(1)$: cross-fitting garante $\mathbb{E}[c^*|S_{-k}] = 0$; desigualdade de Bernstein controla a concentração. a^*: TCL com $\mathbb{E}[V_i\varepsilon_i] = 0$ e variância finita. □

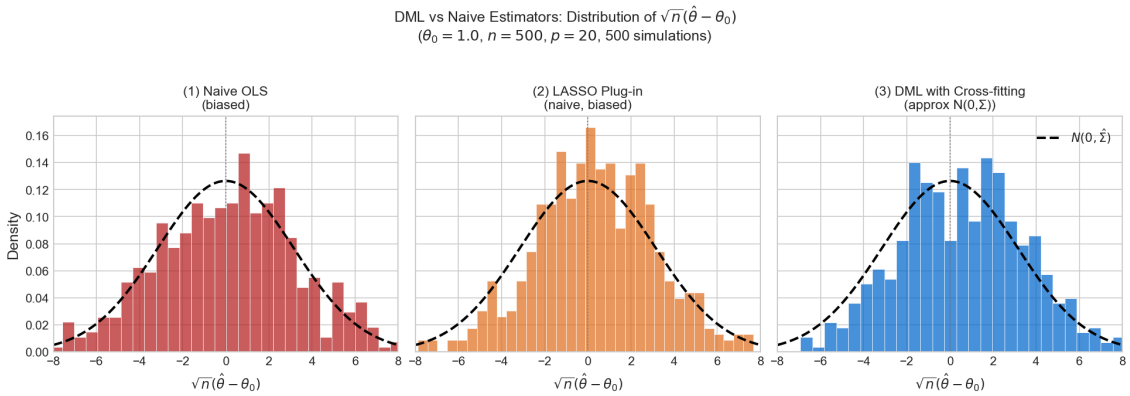

Figura 8.1: Distribuição amostral de $\sqrt{n}(\hat{\theta} - \theta_0)$ em 500 simulações. Esquerda: MQO plug-in — viesado, não-normal. Centro: LASSO plug-in — viesado. Direita: DML com cross-fitting — centrado em zero, bem-aproximado por $N(0, \Sigma)$.

8.5. As Condições de Taxa São Alcançáveis?

Método	Suposição	Taxa por nuisância	Condição DML
LASSO	$s \log p = o(\sqrt{n})$	$\sqrt{s \log p / n}$	Satisfeita
Floresta (Hölder β)	$\beta > d/2$	$n^{-\beta/(2\beta+d)}$	Satisfeita
Rede Neural	Classe Barron	$\sim n^{-1/3}$	Satisfeita

8.6. Modelo Interativo e Estimação Duplamente Robusta

Para tratamento binário $D \in \{0,1\}$ com efeito heterogêneo: $Y_i = g_0(D_i, X_i) + \varepsilon_i$. Alvo: $\text{ATE} = \mathbb{E}[g_0(1,X) - g_0(0,X)]$.

Definição: Score Duplamente Robusto (DR / AIPW)

$$\psi^{\text{DR}} = g_0(1,X) - g_0(0,X) + \frac{D}{\pi(X)}[Y - g_0(1,X)] - \frac{1-D}{1-\pi(X)}[Y - g_0(0,X)].$$

Dupla Robustez

$\mathbb{E}[\psi^{\text{DR}}] = \text{ATE}$ contanto que g_0 *ou* π esteja corretamente especificada.

Demonstração

Se g_0 está correto: $\mathbb{E}[\psi^{\text{DR}}] = \mathbb{E}[g_0(1,X) - g_0(0,X)] + \mathbb{E}[D\varepsilon/\pi(X)] - \mathbb{E}[(1-D)\varepsilon/(1-\pi(X))]$. Os dois últimos: $\mathbb{E}[D\varepsilon/\pi(X)] = \mathbb{E}[\pi(X)\varepsilon/\pi(X)] = \mathbb{E}[\varepsilon] = 0$. Análogo para o outro. Se π está correto: pela fórmula de Horvitz-Thompson, $\mathbb{E}[DY/\pi(X)] - \mathbb{E}[(1-D)Y/(1-\pi(X))] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$. $\square$

8.7. Variáveis Instrumentais no Framework DML

Esta seção estende o conteúdo da aula.

Quando não-confundimento falha mas há instrumento válido Z: $Y_i = \theta_0 D_i + g_0(X_i) + \varepsilon_i$, $\mathbb{E}[\varepsilon_i | Z_i, X_i] = 0$. Defina $\tilde{Z}_i = Z_i - q_0(X_i)$, $\tilde{D}_i = D_i - r_0(Z_i, X_i)$. O estimador:

$$\hat{\theta}^{\text{DML-VI}} = \frac{\mathbb{E}_n[\hat{\tilde{Z}}_i \hat{\tilde{Y}}_i]}{\mathbb{E}_n[\hat{\tilde{Z}}_i \hat{\tilde{D}}_i]},$$

com nuisâncias estimadas por ML com cross-fitting, satisfaz:

$$\sqrt{n}(\hat{\theta}^{\text{DML-VI}} - \theta_0) \xrightarrow{d} N\left(0, \frac{\mathbb{E}[\tilde{Z}^2 \varepsilon^2]}{(\mathbb{E}[\tilde{Z}\tilde{D}])^2}\right).$$

Instrumentos fracos. Quando $\mathbb{E}[\tilde{Z}\tilde{D}] \approx 0$, use testes robustos: Anderson-Rubin, Razão de Verossimilhança Condicional (CLR). O teste F da primeira etapa com $F > 10$ é uma regra prática (Stock & Yogo, 2005).

Referências

Teoria do Aprendizado Estatístico

- Bartlett, P. L. & Mendelson, S. (2002). "Rademacher and Gaussian complexities: risk bounds and structural results." *JMLR*, 3, 463–482.
- Shalev-Shwartz, S. & Ben-David, S. (2014). *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.
- Wainwright, M. J. (2019). *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge University Press.
- Vapnik, V. & Chervonenkis, A. (1971). "On the uniform convergence of relative frequencies." *Theory Prob. Appl.*, 16(2), 264–280.

Regularização

- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2ª ed. Springer.
- Tibshirani, R. (1996). "Regression shrinkage and selection via the lasso." *JRSS-B*, 58(1), 267–288.
- Bickel, P., Ritov, Y. & Tsybakov, A. (2009). "Simultaneous analysis of Lasso and Dantzig selector." *Annals of Statistics*, 37(4), 1705–1732.

Árvores e Florestas

- Breiman, L. (2001). "Random forests." *Machine Learning*, 45, 5–32.
- Scornet, E., Biau, G. & Vert, J.-P. (2015). "Consistency of random forests." *Ann. Statistics*, 43(4), 1716–1741.
- Belkin, M. et al. (2019). "Reconciling modern ML and the bias–variance trade-off." *PNAS*.
- Wager, S. & Athey, S. (2018). "Estimation and inference of heterogeneous treatment effects using random forests." *JASA*.

Redes Neurais

- Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.

- Barron, A. R. (1993). "Universal approximation bounds." *IEEE Trans. Inf. Theory*, 39(3), 930–945.
- Jacot, A., Gabriel, F. & Hongler, C. (2018). "Neural tangent kernel." *NeurIPS*.
- Rumelhart, D., Hinton, G. & Williams, R. (1986). "Learning by back-propagating errors." *Nature*, 323, 533–536.

Inferência Variacional e Modelos Generativos

- Blei, D., Kucukelbir, A. & McAuliffe, J. (2017). "Variational inference: a review." *JASA*.
- Kingma, D. & Welling, M. (2014). "Auto-encoding variational Bayes." *ICLR*.
- Ho, J., Jain, A. & Abbeel, P. (2020). "Denoising diffusion probabilistic models." *NeurIPS*.
- Song, Y. et al. (2021). "Score-based generative modeling through SDEs." *ICLR*.
- Lipman, Y. et al. (2023). "Flow matching for generative modeling." *ICLR*.
- Hyvärinen, A. (2005). "Estimation of non-normalized models by score matching." *JMLR*, 6, 695–709.
- Vincent, P. (2011). "A connection between score matching and denoising autoencoders." *Neural Computation*.

Inferência Causal

- Pearl, J. (2009). *Causalidade: Modelos, Raciocínio e Inferência*, 2ª ed. Cambridge.
- Angrist, J., Imbens, G. & Rubin, D. (1996). "Identification using instrumental variables." *JASA*, 91, 444–455.
- Imbens, G. & Rubin, D. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge.
- Manski, C. (1995). *Identification Problems in the Social Sciences*. Harvard.
- Spirtes, P., Glymour, C. & Scheines, R. (2000). *Causation, Prediction, and Search*, 2ª ed. MIT Press.
- Angrist, J. (1990). "Lifetime earnings and the Vietnam era draft lottery." *AER*, 80(3), 313–336.

Double Machine Learning

- Chernozhukov, V. et al. (2018). "Double/debiased machine learning for treatment and structural parameters." *Econometrics Journal*, 21(1), C1–C68.
- Robinson, P. M. (1988). "Root-N-consistent semiparametric regression." *Econometrica*, 56(4), 931–954.
- Athey, S., Tibshirani, J. & Wager, S. (2019). "Generalized random forests." *Ann. Statistics*.

- Kennedy, E. H. (2023). "Semiparametric doubly robust targeted DML: a review." *Statistical Science*.
- Gómez-Bombarelli, R. et al. (2018). "Automatic chemical design via data-driven representation." *ACS Central Science*.